UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD
DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MÉCANICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



Tesis

"DESARROLLO DE UN SISTEMA BIDIRECCIONAL DE TRADUCCIÓN DE VOZ QUECHUA–ESPAÑOL MEDIANTE ARQUITECTURAS DE TRANSFORMADORES MULTIMODALES PARA CONSULTAS MÉDICAS EN CUSCO"

Para optar al título profesional de:

INGENIERO INFORMÁTICO Y DE SISTEMAS

Presentado por:

Alain Armando Condori Contreras

Código de alumno:

021501

Asesor:

Mtro. Ing. Raúl Huillca Huallparimachi

Perú, Noviembre de 2026

Resumen

En la región Cusco, más del 55 % de la población tiene el quechua como lengua materna y cerca de 70 000 asegurados de EsSalud son quechuahablantes (EsSalud, 2023); esta barrera idiomática afecta la calidad de la atención en salud (Begazo Solís, 2026).

El presente trabajo propone desarrollar y evaluar un sistema bidireccional de traducción de voz Quechua–Español para consultas médicas, que encadena reconocimiento de voz (MMS), traducción automática (NLLB adaptado al quechua de Cusco, `quz`) y síntesis de voz (MMS-TTS) mediante el ajuste (*fine-tuning*) de modelos preentrenados de código abierto.

La salida por voz en ambos sentidos busca incluir a la población quechuahablante con baja o nula alfabetización. La validación se realizará con consultas simuladas, sin datos reales de pacientes, midiendo precisión (WER, BLEU, chrF), calidad de voz (MOS) y percepción de utilidad. Se espera aportar el primer corpus clínico Quechua–Español y evidencia empírica sobre la viabilidad de estas tecnologías en el dominio sanitario andino.

Palabras clave: Traducción automática, Quechua, Procesamiento del lenguaje natural, Comunicación médico-paciente, Inclusión digital.

Abstract

In the Cusco region, more than 55 % of the population has Quechua as their mother tongue and nearly 70,000 EsSalud insured members are Quechua speakers (EsSalud, 2023); this language barrier affects the quality of health care (Begazo Solís, 2026).

This work proposes to develop and evaluate a bidirectional Quechua–Spanish speech translation *system* for medical consultations, chaining speech recognition (MMS), machine translation (NLLB adapted to Cusco Quechua, `quz`) and speech synthesis (MMS-TTS) through the *fine-tuning* of open-source pretrained models.

The two-way voice output aims to include Quechua-speaking people with low or no literacy. Validation will be carried out with simulated consultations, without real patient data, measuring accuracy (WER, BLEU, chrF), voice quality (MOS) and perceived usefulness. The study is expected to contribute the first clinical Quechua–Spanish corpus and empirical evidence on the feasibility of these technologies in the Andean health domain.

Keywords: Machine translation, Quechua, Natural language processing, Doctor–patient communication, Digital inclusion.

Índice general

Resumen **I**

Abstract **II**

Índice de figuras **VI**

Índice de tablas **VII**

Índice de algoritmos **VIII**

Índice de símbolos **IX**

Índice de abreviaturas **X**

Índice de ecuaciones **XI**

Glosario de términos **XII**

I Introducción **1**

1.1 Contexto y problema general 1
1.1.1 Contexto internacional 1
1.1.2 Contexto nacional 2
1.1.3 Contexto regional (Cusco) 3
1.1.4 Planteamiento del problema 4
1.2 Tecnología o método 5
1.3 Vacío de investigación 5
1.4 Formulación del problema 6
1.4.1 Problema general 6
1.4.2 Problemas específicos 6
1.5 Propuesta de solución 6
1.6 Objetivos 7
1.6.1 Objetivo general 7
1.6.2 Objetivos específicos 7
1.7 Justificación 7
1.7.1 Alcances y limitaciones 8
1.8 Organización de la tesis 8

II Marco teórico **10**

2.1 Antecedentes 10
2.1.1 Antecedentes internacionales 10
2.1.2 Antecedentes nacionales 11

2.1.3 Antecedentes locales 12
2.2 Estado del arte y brecha de investigación 13
2.3 Fundamentos teóricos 14
2.3.1 Tecnologías del habla y traducción automática neuronal 14
2.3.2 Modelos multilingües preentrenados (MMS, NLLB, Whisper) . . 14
2.3.3 Ajuste fino y adaptación dialectal (`quy`→`quz`) 15
2.3.4 Arquitectura en cascada ASR→MT→TTS 15
2.3.5 Métricas de evaluación 16
2.4 Definición de términos básicos 16

III Metodología de la investigación 17
3.1 Enfoque, tipo y diseño de investigación 17
3.1.1 Enfoque de investigación 17
3.1.2 Tipo y nivel de investigación 17
3.1.3 Diseño de investigación 17
3.2 Hipótesis 18
3.3 Variables y operacionalización 19
3.3.1 Identificación de variables 19
3.3.2 Matriz de operacionalización de variables 19
3.4 Unidades de análisis y selección de consultas 20
3.4.1 Unidad de análisis 20
3.4.2 Población y muestra 20
3.4.3 Entorno tecnológico (*setup* experimental) 21
3.5 Técnicas e instrumentos de recolección 21
3.6 Procedimiento metodológico 22
3.7 Protocolo de evaluación 22
3.7.1 Métricas de reconocimiento y traducción 22
3.7.2 Métricas de calidad de voz y comprensión 22
3.7.3 Métricas de eficiencia 22
3.7.4 Líneas base (*baselines*) de comparación 23
3.7.5 Criterios de éxito (metas cuantitativas) 23
3.8 Métodos de análisis de datos 23
3.9 Aspectos éticos y de gestión de datos 24
3.10 Matriz de consistencia 25

IV Estudio de factibilidad 26
4.1 Enfoque adoptado 26
4.2 Factibilidad técnica 26
4.2.1 Hardware, cómputo e inferencia 26
4.2.2 Estrategia de datos 26

4.2.3 Herramientas y software 26
4.3 Factibilidad económica 26
4.4 Factibilidad operativa 27
4.5 Análisis de riesgos y mitigación 27
4.6 Viabilidad y sostenibilidad 27

V Aspectos administrativos **28**
5.1 Cronograma de actividades 28
5.2 Presupuesto y financiamiento 28
5.3 Equipo de investigación 29

Referencias **30**

Anexos **34**
Anexo 1: Ficha técnica de registro experimental 34
Anexo 2: Plantilla del banco de frases de consulta (evaluación) 34
Anexo 3: Cuestionario de percepción (escala Likert) 34
Anexo 4: Modelo de consentimiento informado 35

Índice de figuras

1 Magnitud de la problemática en Cusco. 5
2 Pipeline modular **bidireccional** por voz; la traducción NLLB adaptada al quechua de Cusco (`quz`) es el núcleo del aporte. 18

Índice de tablas

1 Síntesis del estado del arte por componente de la cascada. 13
2 Presupuesto de latencia por etapa de la cascada (objetivo por turno). . 15
3 Operacionalización de variables. 19
4 Entorno de hardware y software del experimento. 21
5 Metas de desempeño del prototipo (criterios de éxito). 23
6 Matriz de consistencia del proyecto. 25
7 Matriz de riesgos y mitigación. 27
8 Cronograma de actividades (octubre 2026 – septiembre 2027), por meses. 28
9 Recursos para el desarrollo del proyecto de tesis (soles). 29
10 Equipo de investigación. 29
11 Ficha técnica de registro por turno (plantilla). 34
12 Banco de frases de consulta simulada (ejemplos; `quz` por validar). . . . 34
13 Ítems del cuestionario de percepción. 35

Índice de algoritmos

1 Traducción bidireccional por voz de un turno de diálogo 18

Índice de símbolos

Símbolo	Descripción	Página
α	Nivel de significancia estadística	23
N	Tamaño de muestra / n. de palabras de referencia	16
β	Factor de ponderación recall/precisión en chrF	16
S, D, I	Sustituciones, eliminaciones e inserciones (cálculo del WER)	16
θ	Parámetros (pesos) del modelo ajustado por *fine-tuning*	15
$\mathcal{L}$	Función de pérdida (entropía cruzada) del entrenamiento	15

Índice de abreviaturas

Sigla	**Significado**
IA	Inteligencia artificial
PLN	Procesamiento del lenguaje natural
ASR	Reconocimiento automático del habla (*Automatic Speech Recognition*)
STT	Voz a texto (*Speech-to-Text*)
TTS	Síntesis de voz (*Text-to-Speech*)
MT	Traducción automática (*Machine Translation*)
MMS	*Massively Multilingual Speech* (Meta)
NLLB	*No Language Left Behind* (Meta)
WER	Tasa de error de palabra (*Word Error Rate*)
BLEU	*Bilingual Evaluation Understudy*
chrF	*Character n-gram F-score*
MOS	*Mean Opinion Score*
quz	Quechua Collao / Cusco (código ISO 639-3)
quy	Quechua Ayacucho (código ISO 639-3)
Transformer	Arquitectura de red neuronal basada en autoatención (base de MMS/NLLB)
INEI	Instituto Nacional de Estadística e Informática
EsSalud	Seguro Social de Salud del Perú
UNSAAC	Universidad Nacional de San Antonio Abad del Cusco

Índice de ecuaciones

1 Mecanismo de autoatención del Transformer 14
2 Función de pérdida (entropía cruzada) del ajuste fino 15
3 Tasa de error de palabra (WER) 16
4 Puntaje BLEU 16
5 Puntaje chrF (F-score de n-gramas de caracteres) 16

Glosario de términos

Término	**Definición**
Corpus	Conjunto estructurado de textos o grabaciones usado para entrenar o evaluar modelos.
Fine-tuning	Ajuste de un modelo preentrenado con datos de un dominio específico.
Lengua de bajo recurso	Idioma con escasez de datos digitales para entrenar modelos de PLN.
Modelo preentrenado	Modelo entrenado sobre grandes volúmenes de datos, reutilizable mediante ajuste.
Lengua polisintética	Lengua que concentra mucha información gramatical en una sola palabra, como el quechua.
Pipeline	Secuencia encadenada de etapas (voz $\rightarrow$ texto $\rightarrow$ traducción $\rightarrow$ voz).

Capítulo I

Introducción

En la región Cusco, donde más de la mitad de la población tiene el quechua como lengua materna, la atención en salud opera de manera predominante en español. Esta asimetría levanta una barrera comunicativa entre un personal de salud mayoritariamente castellanohablante y una población usuaria quechuahablante, barrera que —agravada por la baja alfabetización en las zonas rurales andinas— compromete aspectos sensibles del acto médico, desde la recogida de los síntomas hasta la correcta comprensión de las indicaciones.

En paralelo, el procesamiento del lenguaje natural ha alcanzado un punto en el que es posible *adaptar* grandes modelos multilingües preentrenados a lenguas de bajo recurso como el quechua, sin necesidad de entrenarlos desde cero. Sobre esa base, el presente plan propone desarrollar y evaluar un sistema **bidireccional de traducción de voz Quechua–Español** para consultas médicas, que encadena reconocimiento de voz, traducción automática y síntesis de voz, con salida hablada en ambos sentidos del diálogo para incluir también a los usuarios con baja o nula alfabetización.

Este primer capítulo sitúa el problema en sus niveles internacional, nacional y regional, delimita el vacío de investigación y el problema específico, y formula la propuesta con sus objetivos, su justificación y sus alcances. Las hipótesis, por su carácter contrastable, se enuncian en el Capítulo III junto con el diseño metodológico que permite someterlas a prueba.

1.1 Contexto y problema general

El contexto de esta investigación se aborda en tres niveles —internacional, nacional y regional— que, en conjunto, muestran cómo una barrera lingüística histórica se combina hoy con una oportunidad tecnológica inexistente hace pocos años.

1.1.1 Contexto internacional

De las miles de lenguas que se hablan en el mundo, solo una pequeña fracción cuenta con recursos digitales suficientes para sostener tecnologías del lenguaje; la gran mayoría son *lenguas de bajo recurso*, con escasa o nula presencia en los sistemas de voz y traducción automática (Joshi et al., 2020). Esta asimetría digital reproduce, en el plano tecnológico, las desigualdades que ya enfrentan sus hablantes en el acceso a servicios básicos.

En el ámbito sanitario, la comunicación entre un profesional de salud y un paciente que no comparten la misma lengua es un problema reconocido a escala global: la barrera

idiomática compromete la anamnesis, el diagnóstico, el consentimiento informado y la adherencia al tratamiento (Al Shamsi et al., 2020), y por ello el derecho de la persona a ser atendida en su lengua materna se considera un componente de la calidad y la seguridad del acto médico.

En paralelo, el procesamiento del lenguaje natural ha experimentado un cambio de paradigma que abre una ventana de oportunidad para estas lenguas. La estrategia dominante ya no es entrenar modelos desde cero —inviable con pocos datos—, sino adaptar (*fine-tuning*) grandes modelos multilingües preentrenados que incorporan cientos de idiomas: en la voz, MMS (Pratap et al., 2024) y Whisper (Radford et al., 2023); en la traducción, NLLB (NLLB Team, 2022).

Competencias internacionales como AmericasNLP (Mager et al., 2021) y las tareas de traducción de voz de IWSLT (Ortega et al., 2025) han impulsado de forma sostenida el trabajo sobre lenguas indígenas americanas. En este panorama, el quechua —la lengua originaria con mayor número de hablantes de América, extendida por varios países andinos— concentra buena parte de ese esfuerzo, aunque todavía de manera fragmentaria y por componentes aislados.

En el terreno sanitario, la práctica internacional recomendada frente a la barrera idiomática es la mediación lingüística —intérpretes presenciales o telefónicos— (Al Shamsi et al., 2020); sin embargo, su disponibilidad es limitada y prácticamente nula en entornos rurales y de atención primaria, donde ocurre el primer contacto con el sistema de salud.

Por eso las tecnologías del habla —reconocimiento, traducción y síntesis de voz— se perfilan a escala global como un apoyo emergente a la comunicación clínica, con la ventaja decisiva de operar por *voz*: a diferencia de las soluciones basadas en texto, no exigen alfabetización y resultan utilizables por poblaciones con baja escolaridad.

Esta orientación se inscribe en un esfuerzo más amplio de *inclusión digital* y de preservación de las lenguas originarias, hoy reconocido como un objetivo de equidad tecnológica: dotar de presencia digital a una lengua es también una forma de sostener los derechos de sus hablantes.

1.1.2 Contexto nacional

El Perú es un país plurilingüe en el que el quechua es la lengua originaria con mayor número de hablantes. Los Censos Nacionales 2017 registran a millones de peruanos que declaran el quechua como lengua materna, con una marcada concentración en la sierra sur (Instituto Nacional de Estadística e Informática, 2017).

El Estado reconoce el carácter multilingüe del país y el derecho de los ciudadanos a relacionarse con las instituciones públicas en su lengua materna; sin embargo, en la práctica los servicios esenciales —la salud entre ellos— operan de manera predominante en español, lo que condiciona su acceso efectivo para la población quechuahablante.

A esta brecha lingüística se suma una brecha educativa: cerca del 22.8 % de las mujeres rurales no sabe leer ni escribir (Instituto Nacional de Estadística e Informática, 2023), con programas de alfabetización aún limitados en las zonas andinas (Fundación Dispurse, 2023).

Esta doble barrera —de idioma y de alfabetización— implica que una solución tecnológica pertinente para el país no puede basarse solo en texto, sino que debe operar principalmente por *voz*. En el plano institucional ya existen señales de respuesta: EsSalud reactivó en 2023 una central telefónica de atención en quechua (EsSalud, 2023), y la comunidad académica peruana ha producido recursos y modelos iniciales para el quechua en reconocimiento, traducción y síntesis de voz, aunque ninguno orientado a la consulta médica.

El sistema de salud peruano incorpora, al menos en el plano normativo, un enfoque intercultural que reconoce la pertinencia lingüística de la atención (Ministerio de Salud del Perú, 2016); no obstante, su traducción en herramientas operativas dentro del consultorio sigue siendo escasa. La atención primaria se presta en una red amplia y dispersa de establecimientos —postas y centros de salud— situados en zonas andinas donde la población usuaria es mayoritariamente quechuahablante, lo que convierte la distancia idiomática en un problema cotidiano y estructural, no excepcional.

En ese contexto, la investigación nacional en procesamiento del lenguaje para el quechua ha crecido de forma sostenida en la última década, pero se ha concentrado en resolver cada componente por separado —reconocimiento, traducción o síntesis— y sobre dominios generales, sin integrar un sistema completo ni abordar el vocabulario propio de la atención en salud.

1.1.3 Contexto regional (Cusco)

En la región Cusco la presencia del quechua es particularmente intensa: más del 55 % de la población tiene el quechua como lengua materna (Instituto Nacional de Estadística e Informática, 2017). Esta realidad lingüística condiciona el acceso efectivo a los servicios públicos esenciales —la atención en salud entre ellos— cuando operan de manera predominante en español.

La red de salud de Cusco atiende a una población extensa y geográficamente dispersa, con numerosas comunidades rurales y altoandinas donde el quechua es la lengua de uso cotidiano y el español tiene presencia limitada.

A esta realidad se suma una particularidad lingüística decisiva para la propuesta: el quechua de Cusco corresponde a la variante Collao (`quz`), distinta de la de Ayacucho (`quy`) tanto en léxico como en rasgos fonológicos; esta diferencia dialectal —no menor para un sistema automático— es justamente la que los modelos de traducción disponibles aún no cubren para Cusco.

Por añadidura, la consulta médica no es solo un intercambio de información, sino

un encuentro cultural en el que la confianza y la comprensión mutua condicionan la adherencia al tratamiento; cuando esa comunicación falla, el riesgo clínico recae sobre la población más vulnerable.

1.1.4 Planteamiento del problema

Los tres niveles de contexto —internacional, nacional y regional— convergen en un problema concreto y localizado: la comunicación clínica en la consulta cara a cara de los establecimientos de salud de Cusco, donde el idioma se vuelve un determinante directo de la calidad y la seguridad de la atención.

En el ámbito sanitario, la distancia idiomática entre un personal de salud mayoritariamente castellanohablante y una población usuaria quechuahablante origina una barrera comunicativa con consecuencias clínicas directas.

EsSalud reconoce que cerca de 70 000 de sus asegurados en Cusco son quechuahablantes y reactivó en 2023 la central telefónica en quechua (EsSalud, 2023); sin embargo, esa medida —de alcance telefónico y unidireccional— no alcanza la interacción cara a cara del consultorio, donde se recogen síntomas, se formula el diagnóstico y se entregan las indicaciones.

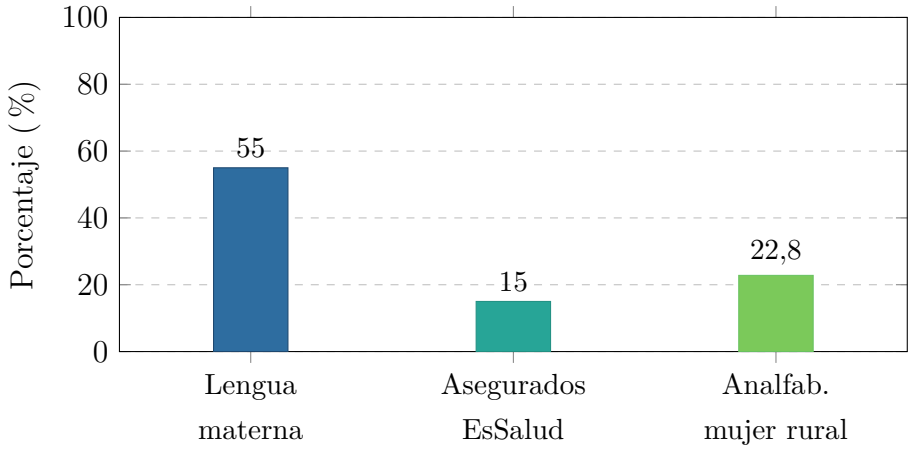
La evidencia confirma la gravedad del problema: Begazo Solís (2026) documenta cómo la desconexión idiomática vulnera la relación terapéutica en hospitales de Cusco, y Cuaila (2022) halla una relación entre el conocimiento del quechua del personal y la calidad de atención percibida. A ello se suma una barrera de alfabetización: cerca del 22.8 % de las mujeres rurales no sabe leer ni escribir (Instituto Nacional de Estadística e Informática, 2023), lo que obliga a una solución basada en *voz* y no solo en texto (Figura 1).

Las consecuencias de esta barrera no son menores: una anamnesis incompleta, un diagnóstico tardío o una indicación mal comprendida comprometen la seguridad del acto médico y la adherencia al tratamiento, y recaen sobre la población más vulnerable. Pese a ello, las respuestas institucionales vigentes son parciales —telefónicas, unidireccionales o dependientes de la disponibilidad de personal bilingüe— y no existe una herramienta que asista la traducción por voz, en ambos sentidos, durante la propia consulta.

En síntesis, el problema general que motiva este plan es la **barrera comunicativa entre el personal de salud castellanohablante y los pacientes quechuahablantes de Cusco** durante la consulta cara a cara, agravada por la baja alfabetización y no resuelta por las medidas vigentes. Existiendo hoy modelos multilingües preentrenados que cubren parcialmente el quechua, la pregunta es si pueden adaptarse e integrarse en un sistema de traducción por voz, bidireccional, para asistir esa interacción clínica.

Figura 1

Magnitud de la problemática en Cusco.



Nota. Elaboración propia con datos de Instituto Nacional de Estadística e Informática (2017), EsSalud (2023) e Instituto Nacional de Estadística e Informática (2023).

1.2 Tecnología o método

El estado del arte en procesamiento del lenguaje natural ofrece hoy una oportunidad que no existía hace pocos años. La estrategia dominante para lenguas de bajo recurso ya no consiste en entrenar modelos desde cero, sino en adaptar (*fine-tuning*) grandes modelos multilingües preentrenados.

En la voz, el proyecto MMS (Pratap et al., 2024) cubre el quechua de Cusco (`quz`) en reconocimiento y síntesis; Whisper (Radford et al., 2023) declara una cobertura marginal del quechua y se reserva como línea base. En traducción, NLLB (NLLB Team, 2022) incluye el quechua de Ayacucho (`quy`) y no el de Cusco, por lo que el par debe adaptarse a `quz` —esa brecha dialectal es el núcleo del aporte técnico—.

Existen además antecedentes de traducción neural para esta lengua polisintética (Mager et al., 2021; Ortega et al., 2020) y recursos como el corpus *Huqariq* (Zevallos, Camacho & Melgarejo, 2022).

1.3 Vacío de investigación

Persiste una desconexión entre ambos mundos: el problema social está bien documentado y la tecnología base existe, pero nadie ha unido los dos extremos. No se dispone de un corpus clínico Quechua–Español ni de una evaluación empírica del desempeño de estos modelos sobre el vocabulario propio de la consulta médica (triaje, síntomas e indicaciones), y NLLB aún no cubre la variante de Cusco (`quz`). Cerrar esa intersección es el aporte de este proyecto.

1.4 Formulación del problema

La formulación del problema de esta investigación se concentra en la comunicación médico-paciente mediada por un sistema bidireccional de traducción de voz Quechua–Español basado en modelos preentrenados, y en la medida en que su ajuste al dominio clínico mejora la precisión y la comprensión frente a la ausencia de apoyo tecnológico.

1.4.1 Problema general

¿Cómo *desarrollar un sistema bidireccional de traducción de voz Quechua–Español mediante arquitecturas de transformadores multimodales* (ajuste fino de los modelos preentrenados MMS y NLLB) *para la comunicación médico-paciente en las consultas médicas en Cusco*?

1.4.2 Problemas específicos

1. **(PE1 — Diagnóstico).** ¿Cuáles son las barreras de comunicación entre el personal de salud y los pacientes quechuahablantes, y qué debe contener el corpus clínico Quechua–Español (triaje, síntomas e indicaciones) para poder ajustar los modelos? **Aporte:** Permite construir el corpus clínico etiquetado; sin esos datos no es posible ajustar los modelos.

2. **(PE2 — Construcción).** ¿Cómo construir el sistema de traducción por voz, ajustando (*fine-tuning*) los modelos preentrenados MMS y NLLB —del quechua de Ayacucho (`quy`) al de Cusco (`quz`)— e integrándolos en un *pipeline* ASR+MT+TTS? **Aporte:** Es el núcleo de la solución: el sistema con el modelo de traducción adaptado al dominio clínico y a la variante de Cusco.

3. **(PE3 — Validación).** ¿En qué medida el sistema mejora la precisión de la traducción (WER, BLEU, chrF), la calidad de la voz (MOS) y la comprensión entre el médico y el paciente, frente a no contar con apoyo tecnológico? **Aporte:** Demuestra si el sistema resuelve el problema general.

1.5 Propuesta de solución

Se propone desarrollar y evaluar un sistema bidireccional de traducción de voz Quechua–Español para consultas médicas, que encadena reconocimiento de voz (MMS), traducción automática (NLLB adaptado de `quy` a `quz`) y síntesis de voz (MMS-TTS) mediante el ajuste de modelos preentrenados de código abierto, con salida por voz en ambos sentidos del diálogo.

1.6 Objetivos

1.6.1 Objetivo general

Desarrollar un sistema bidireccional de traducción de voz Quechua–Español para la comunicación médico-paciente, mediante arquitecturas de transformadores multimodales (ajuste fino de los modelos preentrenados MMS y NLLB), en las consultas médicas en Cusco.

1.6.2 Objetivos específicos

1. **(OE1 — Diagnóstico).** Caracterizar las barreras de comunicación entre el personal de salud y los pacientes quechuahablantes y determinar qué debe contener el corpus clínico Quechua–Español (triaje, síntomas e indicaciones) para poder ajustar los modelos.

2. **(OE2 — Construcción).** Construir el sistema de traducción por voz, ajustando (*fine-tuning*) los modelos preentrenados MMS y NLLB —del quechua de Ayacucho (`quy`) al de Cusco (`quz`)— e integrándolos en un *pipeline* ASR+MT+TTS con salida por voz y texto.

3. **(OE3 — Validación).** Evaluar en qué medida el sistema mejora la precisión de la traducción (WER, BLEU, chrF), la calidad de la voz (MOS) y la comprensión entre el médico y el paciente, frente a no contar con apoyo tecnológico.

1.7 Justificación

La investigación se justifica en cuatro dimensiones:

- **Teórica:** Aporta evidencia empírica del desempeño de modelos preentrenados en una lengua de bajo recurso y morfología compleja.
- **Práctica:** Entrega un prototipo piloteable en un centro de salud.
- **Social:** Ataca una inequidad documentada en el acceso a la salud (Begazo Solís, 2026), en línea con el derecho de los pacientes a ser atendidos en su lengua materna (EsSalud, 2023).
- **Metodológica:** Establece un proceso replicable (corpus + ajuste + evaluación) aplicable a otras variantes del quechua o a otros dominios.

Entre las **contribuciones originales esperadas** destacan:

- El **primer corpus de dominio médico** Quechua–Español para tecnologías del habla.

- La **adaptación de NLLB de `quy` a `quz`** en el dominio clínico (aporte técnico central).
- Un **sistema integrado ASR+MT+TTS** con salida por voz para usuarios con baja alfabetización.

En conjunto, el proyecto contribuye a la equidad en el acceso a la salud de la población quechuahablante de Cusco, a la seguridad del acto médico y a la revitalización y el prestigio digital del quechua.

1.7.1 Alcances y limitaciones

Alcances.

- Par lingüístico Quechua de Cusco (`quz`) – Español, en ambos sentidos.
- Vocabulario acotado de consulta general (triaje, síntomas, indicaciones).
- Prototipo integrado ASR+MT+TTS con salida por voz y texto.
- Validación con consultas simuladas en un centro de salud de referencia en Cusco.

Limitaciones.

- **Temporal:** Ejecución entre octubre 2026 y septiembre 2027 (12 meses).
- **Ética:** Se emplean diálogos simulados/actuados, sin datos reales de pacientes.
- Desempeño condicionado por la escasez de datos de dominio clínico en quechua.
- Resultados circunscritos a la variante de Cusco; no generalizables sin ajuste a otras variantes.

1.8 Organización de la tesis

El documento se organiza en cinco capítulos:

- **Capítulo I — Introducción:** contexto, tecnología, vacío de investigación, problema, propuesta, objetivos y justificación.
- **Capítulo II — Marco teórico:** fundamentos teóricos y estado del arte derivado de la revisión sistemática.
- **Capítulo III — Metodología:** enfoque, diseño, hipótesis, variables, unidades de análisis, técnicas, procedimiento, protocolo de evaluación y aspectos éticos.
- **Capítulo IV — Factibilidad:** análisis de la factibilidad técnica, económica y operativa.

- **Capítulo V — Aspectos administrativos:** cronograma, presupuesto y equipo.

La **matriz de consistencia**, incluida al cierre del Capítulo III, articula de forma integral el problema, los objetivos, las hipótesis, las variables y la metodología.

Capítulo II

Marco teórico

2.1 Antecedentes

Los trabajos previos sobre tecnologías del habla y traducción automática para el quechua se organizan en tres niveles —internacional, nacional y local—. En conjunto evidencian avances sólidos por componente (ASR, MT y TTS), pero ninguno aborda su integración en el dominio médico-paciente ni la variante de Cusco (`quz`).

A continuación se desarrollan los antecedentes más relevantes siguiendo, en cada caso, cinco elementos: (i) la cita y el título del estudio, (ii) su diseño metodológico, (iii) los instrumentos o modelos empleados, (iv) sus resultados y conclusión principal, y (v) su aporte a la presente tesis. Al final, la Tabla 1 sintetiza el conjunto por componente.

2.1.1 Antecedentes internacionales

Antecedente 1.

- **Cita y título:** Ortega et al. (2020), *Neural machine translation with a polysynthetic low resource language* (revista *Machine Translation*); primer trabajo de traducción automática neuronal Español–Quechua.
- **Diseño metodológico:** Enfoque cuantitativo, diseño experimental, orientado a superar la escasez de datos de una lengua polisintética.
- **Instrumentos:** Redes neuronales de traducción con segmentación morfológica (subpalabras guiadas por la morfología), evaluadas con la métrica BLEU.
- **Resultados y conclusión:** La segmentación morfológica mejora la traducción frente a la línea base; concluyen que el tratamiento explícito de la morfología es decisivo en lenguas aglutinantes.
- **Aporte a la tesis:** Justifica lingüísticamente el problema y fundamenta el tratamiento morfológico específico del quechua al ajustar los modelos de traducción.

Antecedente 2.

- **Cita y título:** Ortega et al. (2023, 2025), serie *QUESPA Submission for the IWSLT Dialectal and Low-resource Speech Translation Task* (IWSLT, 2023–2025); traducción de voz Quechua–Español.
- **Diseño metodológico:** Experimental y comparativo entre ediciones sucesivas.

- **Instrumentos:** Arquitectura en cascada (reconocimiento de voz seguido de traducción) sobre modelos multilingües preentrenados (MMS y NLLB) afinados por transferencia, evaluados con BLEU.
- **Resultados y conclusión:** El desempeño subió de cerca de 16 a **26.7 BLEU** (2023–2025), incorporando en 2025 la variante Collao/Cusco (`quz`); concluyen que el ajuste de modelos preentrenados es la vía más eficaz para esta lengua.
- **Aporte a la tesis:** Es el antecedente más cercano; aporta la arquitectura en cascada y el protocolo de evaluación que se reutilizan, y revela la brecha a cerrar (la variante `quz` y el dominio clínico, aún no resueltos de extremo a extremo).

2.1.2 Antecedentes nacionales

Antecedente 3.

- **Cita y título:** Zevallos et al. (2020), *Automatic Speech Recognition of Quechua Language Using HMM Toolkit* (Springer, CCIS); reconocedor de voz para el quechua.
- **Diseño metodológico:** Cuantitativo-experimental.
- **Instrumentos:** Modelos ocultos de Markov (HMM/HTK) entrenados sobre un corpus de voz quechua, evaluados con la tasa de error de palabra (WER).
- **Resultados y conclusión: 12.70 % de WER** y, con aumento de datos (Zevallos, Bel et al., 2022), 22.75 % de WER sobre datos más variados; concluyen que la escasez de datos es el principal limitante del ASR quechua.
- **Aporte a la tesis:** Establece una línea base nacional de WER para el módulo de reconocimiento y respalda el aumento de datos ante la escasez de corpus clínico.

Antecedente 4.

- **Cita y título:** Huamán Curo y Pineda Ancco (2026), *Quechua Speech Synthesizers* (Springer, CCIS); síntesis de voz para el quechua.
- **Diseño metodológico:** Experimental y comparativo entre cuatro arquitecturas de TTS.
- **Instrumentos:** Modelos neuronales de síntesis entrenados sobre quechua chanca, valorados con el *Mean Opinion Score* (MOS) mediante juicios perceptuales.
- **Resultados y conclusión:** MOS de hasta **4.9**, cercano a la voz humana; concluyen que es viable generar voz quechua de alta naturalidad con arquitecturas actuales.

- **Aporte a la tesis:** Confirma la factibilidad del módulo de salida por voz (TTS) —clave para usuarios con baja alfabetización— y valida el MOS como instrumento de medición.

Antecedente 5.

- **Cita y título:** Cueva Medina et al. (2024), *Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish* (LACCEI); traducción neuronal Quechua–Español.
- **Diseño metodológico:** Aplicado, de diseño experimental.
- **Instrumentos:** Modelo de traducción neuronal optimizado con representaciones tipo BERT, evaluado con métricas de traducción (BLEU/chrF).
- **Resultados y conclusión:** Mejoras al incorporar modelos preentrenados frente a enfoques previos; concluyen que la transferencia desde modelos de lenguaje mejora la traducción en contextos de bajo recurso.
- **Aporte a la tesis:** Confirma, en el contexto peruano, la estrategia de *fine-tuning* sobre modelos preentrenados que aquí se adopta para la adaptación dialectal `quy`→`quz`.

2.1.3 Antecedentes locales

Antecedente 6.

- **Cita y título:** Begazo Solís (2026), *Barreras lingüísticas y culturales en la atención hospitalaria: la experiencia de pacientes quechua-hablantes* (proyecto de investigación); barrera idiomática en hospitales de referencia de Cusco.
- **Diseño metodológico:** Estudio de campo centrado en la experiencia de los pacientes.
- **Instrumentos:** Técnicas de recolección sobre la interacción clínica real.
- **Resultados y conclusión:** Documenta cómo la desconexión idiomática vulnera la relación terapéutica y concluye que la barrera compromete la calidad y la seguridad de la atención; en una región andina vecina, Cuaila (2022) halló una relación directa entre el dominio del quechua del personal y la calidad de atención percibida.
- **Aporte a la tesis:** Aporta la evidencia local del problema que motiva la propuesta y respalda la pertinencia de una solución por voz para el consultorio cusqueño.

En el plano tecnológico local, el primer sistema de traducción neural para el quechua se desarrolló con participación de *Hinantin Software* de Cusco (Ortega et al., 2020), y

la variante Collao/Cusco (quz) fue incorporada recién en la campaña QUESPA 2025 (Ortega et al., 2025). A ello se suma el reto de la alfabetización en zonas rurales andinas (Fundación Dispurse, 2023; Instituto Nacional de Estadística e Informática, 2023).

Complementan este panorama otros antecedentes nacionales e internacionales: la traducción de voz en cascada Español→Quechua (Alvarez-Crespo et al., 2023), los enfoques multilingües para las lenguas del Perú (Moreno Véliz, 2021; Oncevay, 2021), la segmentación morfológica (W. Chen & Fazio, 2021) y las representaciones autosupervisadas (C.-C. Chen et al., 2024).
A ello se suman el aumento de datos sintéticos (Ahmed et al., 2023; Dhawan et al., 2026; Ebrahimi et al., 2024; Gow-Smith & Sánchez Villegas, 2023) y recursos como *QuBERT* (Zevallos, Ortega et al., 2022), *Huqariq* (Zevallos, Camacho & Melgarejo, 2022) y la API *Siminchikkunarayku* (Guzman et al., 2021), todos sintetizados en la Tabla 1.

No se identificó ningún antecedente local que integre reconocimiento, traducción y síntesis de voz para la atención en salud, lo que confirma la pertinencia de esta investigación.

2.2 Estado del arte y brecha de investigación

A partir de una **revisión sistemática** (Scopus, IEEE Xplore y ACM Digital Library; 62 registros identificados, 58 tras depurar duplicados y 30 evaluados a texto completo), los antecedentes de la sección anterior se sintetizan por componente en la Tabla 1 —sin repetir las citas ya detalladas—, lo que permite ubicar con precisión qué se ha resuelto y qué sigue abierto.

Tabla 1
Síntesis del estado del arte por componente de la cascada.

Componente	**Avance / mejor resultado reportado**	**¿Salud?**
ASR (quechua)	WER 12.70 % (HMM/HTK) y 22.75 % con aumento de datos	No
MT (QU–ES)	Hasta +11 % chrF; BLEU 15.47 con modelos ajustados	No
TTS (quechua)	MOS de hasta 4.9 (XTTS v2)	No
Traducción de voz (cascada)	26.7 BLEU (QUESPA 2025, variante Collao)	No
Recursos / corpus	QuBERT, *Huqariq*, API *Siminchikkunarayku*	Habilitador

Nota. Elaboración propia a partir de la revisión sistemática (Scopus, IEEE Xplore y ACM); síntesis por componente. La columna "¿Salud?" indica si el trabajo abordó el dominio sanitario.

La síntesis evidencia avances sólidos por componente, pero ninguno en el **dominio clínico** ni con la variante de Cusco (quz) integrada de extremo a extremo. La **brecha** es, por tanto, la intersección —hoy vacía— entre las tecnologías del habla para

el quechua y la comunicación médico-paciente: no existe un corpus clínico Quechua–Español ni una evaluación empírica de estos modelos en salud, y NLLB aún no cubre `quz`. Cerrar esa intersección es el aporte de este proyecto.

2.3 Fundamentos teóricos

2.3.1 Tecnologías del habla y traducción automática neuronal

El **reconocimiento automático de voz (ASR)** convierte una señal de voz en texto; la **traducción automática (MT)**, hoy mayoritariamente *neuronal* con arquitecturas Transformer, traduce entre idiomas; y la **síntesis de voz (TTS)** genera voz a partir de texto. En **lenguas de bajo recurso** —como el quechua, de morfología polisintética— estas tareas se benefician de la transferencia desde modelos entrenados sobre grandes volúmenes de datos multilingües.

La base común de estos modelos es la arquitectura *Transformer* (Vaswani et al., 2017), cuyo núcleo es el mecanismo de *autoatención*: cada token se proyecta en consultas Q, claves K y valores V, y la atención pondera la información relevante del contexto mediante

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V, \tag{1}$$

donde d_k es la dimensión de las claves y el factor $1/\sqrt{d_k}$ estabiliza los gradientes. Este mecanismo modela dependencias de largo alcance, decisivo en una lengua polisintética como el quechua, donde una sola palabra concentra mucha información gramatical.

Si bien comparten esta base, los modelos de la cascada operan sobre *modalidades* distintas —habla (audio) y texto—: el ASR y la TTS procesan la señal de voz, mientras que la MT trabaja sobre texto. Por ello, su integración constituye una **arquitectura de transformadores multimodales**, en la que un mismo principio de autoatención se aplica a secuencias acústicas y textuales para lograr una traducción bidireccional por voz.

2.3.2 Modelos multilingües preentrenados (MMS, NLLB, Whisper)

MMS (Pratap et al., 2024) cubre el quechua de Cusco (`quz`) en reconocimiento y síntesis; **NLLB** (NLLB Team, 2022) ofrece traducción multilingüe que incluye el quechua de Ayacucho (`quy`); y **Whisper** (Radford et al., 2023) se emplea como referencia de ASR con cobertura marginal del quechua. Estos modelos permiten reutilizar conocimiento lingüístico general y especializarlo mediante ajuste.

Conviene distinguir la *teoría* de la *herramienta*: el Transformer (ecuación 1) es el modelo abstracto, mientras que MMS, NLLB y Whisper son *frameworks* preentrenados que lo implementan y que en esta tesis se reutilizan por ajuste fino.

2.3.3 Ajuste fino y adaptación dialectal (quy→quz)

El *ajuste fino* (*fine-tuning*) adapta un modelo preentrenado a un dominio o variante específicos con relativamente pocos datos. El aporte técnico central de esta tesis es la adaptación del par de traducción del quechua de Ayacucho (quy) al de Cusco (quz) sobre el vocabulario clínico, cerrando la brecha dialectal que hoy limita a NLLB.
Formalmente, partiendo de los pesos preentrenados θ_0, el ajuste minimiza la *entropía cruzada* sobre el corpus de dominio $\mathcal{D}$:

$$\mathcal{L}(\theta) = -\sum_{(x,y)\in\mathcal{D}} \sum_{t=1}^{|y|} \log P_\theta(y_t \mid y_{<t},\, x)\,, \tag{2}$$

y los parámetros se actualizan por descenso de gradiente $\theta \leftarrow \theta - \eta\,\nabla_\theta \mathcal{L}(\theta)$, con tasa de aprendizaje η. De este modo, el ajuste reorienta la distribución del modelo hacia el vocabulario clínico y la variante quz; esta es la base teórica que explica la reducción esperada del WER y la mejora de BLEU/chrF postuladas en la hipótesis H2.

2.3.4 Arquitectura en cascada ASR→MT→TTS

El encadenamiento de los tres componentes en una **arquitectura en cascada** habilita un diálogo bidireccional por voz: la voz del hablante se transcribe (ASR), el texto se traduce (MT) y la traducción se reproduce en la lengua del interlocutor (TTS). La modularidad facilita ajustar y evaluar cada etapa por separado.
El flujo de datos es $a \xrightarrow{\text{ASR}} t_s \xrightarrow{\text{MT}} t_t \xrightarrow{\text{TTS}} a_t$: la señal de audio a se transcribe a texto origen t_s, se traduce a texto destino t_t y se sintetiza como audio a_t (véase el Algoritmo 1 del Capítulo III). Al ser etapas secuenciales, la latencia por turno es aditiva, $T = T_{\text{ASR}} + T_{\text{MT}} + T_{\text{TTS}}$; el presupuesto objetivo se resume en la Tabla 2, lo que justifica evaluar cada módulo por separado y su integración.

Tabla 2
Presupuesto de latencia por etapa de la cascada (objetivo por turno).

Etapa	**Operación**	**Latencia objetivo (s)**
ASR (MMS)	Voz → texto origen (t_s)	$\leq 1{,}5$
MT (NLLB)	Texto origen → texto destino (t_t)	$\leq 1{,}0$
TTS (MMS)	Texto destino → voz (a_t)	$\leq 1{,}5$
Total por turno (T)		$\leq$ **4,0**

Nota. Valores objetivo para el prototipo en equipo de gama media; se verifican empíricamente en el Capítulo III (métricas de eficiencia).

2.3.5 Métricas de evaluación

El desempeño se mide con métricas estandarizadas: **WER** para el reconocimiento, **BLEU** (Papineni et al., 2002) y **chrF** (Popović, 2015) para la traducción —esta última adecuada para lenguas morfológicamente ricas— y **MOS** para la naturalidad de la voz sintetizada.
Se definen formalmente a continuación. La *tasa de error de palabra* compara la transcripción con la referencia:

$$\mathrm{WER} = \frac{S + D + I}{N}, \tag{3}$$

con S, D e I sustituciones, eliminaciones e inserciones sobre N palabras de referencia. *BLEU* mide la precisión de n-gramas con penalización por brevedad (BP):

$$\mathrm{BLEU} = \mathrm{BP} \cdot \exp\Big(\textstyle\sum_{n=1}^{4} w_n \log p_n\Big), \tag{4}$$

donde p_n es la precisión de n-gramas y w_n su peso. *chrF*, más robusta en morfología rica, es la media armónica ponderada de precisión (chrP) y *recall* (chrR) de n-gramas de *caracteres*:

$$\mathrm{chrF}_\beta = (1 + \beta^2)\,\frac{\mathrm{chrP} \cdot \mathrm{chrR}}{\beta^2\,\mathrm{chrP} + \mathrm{chrR}}. \tag{5}$$

Por último, el *Mean Opinion Score* es el promedio de J juicios perceptuales $m_j \in [1, 5]$, es decir $\mathrm{MOS} = \frac{1}{J}\sum_{j=1}^{J} m_j$. La aplicación operativa de estas métricas se retoma en el Capítulo III.

2.4 Definición de términos básicos

- **Corpus:** Conjunto estructurado de textos o grabaciones para entrenar o evaluar modelos.
- **Modelo preentrenado:** Modelo entrenado sobre grandes volúmenes de datos, reutilizable mediante ajuste.
- **Lengua de bajo recurso:** Idioma con escasez de datos digitales para el PLN.
- **Lengua polisintética:** Lengua que concentra mucha información gramatical en una sola palabra, como el quechua.
- **Pipeline:** Secuencia encadenada de etapas (voz → texto → traducción → voz).

Capítulo III

Metodología de la investigación

3.1 Enfoque, tipo y diseño de investigación

3.1.1 Enfoque de investigación

La investigación adopta un enfoque **cuantitativo** (Hernández-Sampieri & Mendoza Torres, 2018): todas las variables —tanto las de desempeño (WER, BLEU, chrF, MOS, latencia) como las de percepción (escalas Likert y MOS)— se miden con instrumentos numéricos y se analizan con estadística descriptiva e inferencial, sin recurrir a categorías cualitativas.

3.1.2 Tipo y nivel de investigación

Siguiendo a Hernández-Sampieri y Mendoza Torres (2018), es de tipo **aplicado** —resuelve un problema concreto mediante el desarrollo de un prototipo, sin buscar teoría nueva— y de nivel **aplicativo**, con alcance *descriptivo* en la fase de diagnóstico (caracterización de barreras y requerimientos) y *explicativo* en la validación, al contrastar el efecto del sistema frente a la ausencia de apoyo tecnológico.

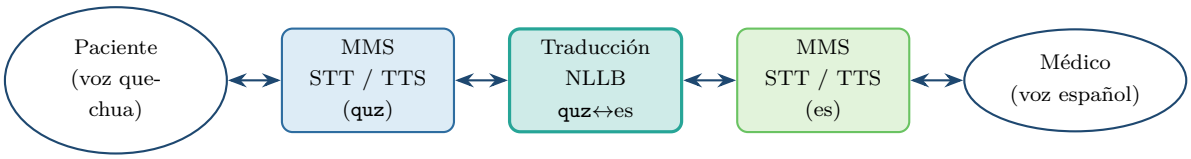
La investigación se organiza en las tres fases del modelo de ingeniería —**diagnóstico**, **construcción** y **validación**—, en correspondencia con los tres objetivos específicos.

3.1.3 Diseño de investigación

El diseño es **experimental, de tipo cuasi-experimental con medidas repetidas (intra-sujeto)**: se manipula la variable independiente —uso del sistema y modalidad de salida— y cada unidad se mide en dos condiciones (con sistema *vs.* sin sistema; texto *vs.* texto+voz), actuando como su propio control. Esta estructura de medidas pareadas fortalece la comparación causal frente a un diseño pre-experimental de un solo grupo, sin requerir la aleatorización de grupos —inviable con una población lingüística acotada—; la unidad de análisis es el *turno de traducción* dentro de una consulta simulada. La Figura 2 muestra el flujo del sistema y el Algoritmo 1 detalla el procesamiento de un turno de diálogo.

Figura 2

*Pipeline modular **bidireccional** por voz; la traducción NLLB adaptada al quechua de Cusco (`quz`) es el núcleo del aporte.*



Nota. Elaboración propia. El bloque central (traducción NLLB quz↔es) concentra la adaptación dialectal, núcleo del aporte de la tesis.

Algoritmo 1 Traducción bidireccional por voz de un turno de diálogo

Require: Audio de entrada a; idioma origen L_s; idioma destino L_t

Ensure: Texto traducido t_t y audio sintetizado a_t

1: $t_s \leftarrow \mathrm{STT}_{\mathrm{MMS}}(a,\, L_s)$
2: $t_t \leftarrow \mathrm{MT}_{\mathrm{NLLB}}(t_s,\, L_s \rightarrow L_t)$
3: Mostrar t_t en pantalla
4: $a_t \leftarrow \mathrm{TTS}_{\mathrm{MMS}}(t_t,\, L_t)$
5: Reproducir a_t
6: **return** $(t_t,\, a_t)$

Nota. Elaboración propia, basada en la arquitectura en cascada ASR→MT→TTS descrita en el Capítulo II.

Las funciones STT, MT y TTS no son cajas negras: internamente aplican la autoatención del Transformer (ecuación 1) sobre secuencias de *tokens*, con los pesos θ previamente especializados por *fine-tuning* (ecuación 2). Así, el paso 2 (MT con NLLB) es el que concentra la adaptación dialectal `quy`→`quz`, aporte central de la tesis.

3.2 Hipótesis

Hipótesis general: Un sistema bidireccional de traducción de voz Quechua–Español, basado en arquitecturas de transformadores multimodales (modelos preentrenados MMS y NLLB ajustados por *fine-tuning*), mejora significativamente la comunicación médico-paciente durante las consultas médicas en Cusco frente a la ausencia de apoyo tecnológico.

- **H1 (Diagnóstico** —proposición descriptiva**):** La comunicación médico-paciente con pacientes quechuahablantes presenta barreras lingüísticas *caracterizables*, cuya identificación define los requisitos —léxico clínico y escenarios de triaje, síntomas e indicaciones— del corpus Quechua–Español. Al ser diagnóstica, H1 se verifica por caracterización (cobertura léxica y concordancia entre expertos), no por un contraste estadístico de medias.

- **H2 (Construcción):** El ajuste (*fine-tuning*) de los modelos preentrenados integrados en el *pipeline* reduce el WER y mejora el BLEU/chrF frente a los modelos sin ajustar.
- **H3 (Validación):** El uso del sistema mejora significativamente la precisión, la calidad de la voz y la comprensión mutua en la comunicación médico-paciente frente a la ausencia de apoyo tecnológico, sobre todo con baja alfabetización.

H2 y H3 son hipótesis *contrastables* —se someten a prueba estadística (t de Student o Wilcoxon, según normalidad)—, mientras que H1 es una proposición diagnóstica que se valida por caracterización. Todas se articulan de forma integral en la matriz de consistencia (Tabla 6).

3.3 Variables y operacionalización

3.3.1 Identificación de variables

La **variable independiente** es el sistema de traducción (con o sin sistema) y la modalidad de salida (texto / texto+voz). Las **variables dependientes** son la precisión de transcripción y traducción, la calidad de la voz y la comprensión/percepción. El nivel de alfabetización actúa como **variable interviniente**.

3.3.2 Matriz de operacionalización de variables

La Tabla 3 resume la operacionalización.

Tabla 3
Operacionalización de variables.

Variable	Definición / dimensión	Indicador
Independiente	Uso del sistema de traducción	Con / sin sistema
	Modalidad de salida	Texto / texto+voz
Dependiente	Precisión de transcripción	WER
	Precisión de traducción	BLEU / chrF
	Comprensión y percepción	% aciertos, Likert, MOS
Interviniente	Nivel de alfabetización	Alto / bajo

Nota. Elaboración propia. WER: tasa de error de palabra; BLEU/chrF: métricas de traducción; MOS: *Mean Opinion Score* (ecuaciones del Capítulo II).

3.4 Unidades de análisis y selección de consultas

3.4.1 Unidad de análisis

La unidad de análisis es el *turno de traducción* dentro de una consulta simulada (una intervención hablada que el sistema reconoce, traduce y reproduce). Los escenarios cubren triaje, síntomas e indicaciones.

3.4.2 Población y muestra

Población. Es el universo de enunciados o *turnos* de habla propios de la comunicación médico-paciente en consultas generales —triaje, síntomas e indicaciones— en el par quechua de Cusco (`quz`)–español. Al tratarse de un universo *lingüístico* y no de un conjunto de personas, se cuantifica en unidades de diálogo (turnos), no en individuos.
Muestra. Es el *corpus clínico* construido *ad hoc* para el estudio: un banco de frases-guión por escenario con sus grabaciones de audio, del orden de 30–50 frases-guión por escenario (triaje, síntomas e indicaciones) —aproximadamente 90–150 en total—, revisadas y validadas con hablantes nativos de la variante de Cusco.
Partición y control de fuga de datos. El corpus se divide en los subconjuntos de *entrenamiento* (70 %), *validación* (15 %) y *prueba* (15 %), con separación estricta: el conjunto de prueba *no* participa en el ajuste, de modo que las métricas (WER, BLEU, chrF) se reportan siempre sobre datos no vistos y no quedan infladas por sobreajuste. Dado el tamaño reducido, la estimación se robustece con *validación cruzada k-fold* ($k = 5$), reportando la media y la desviación de cada métrica.
Rol del corpus y aumento de datos. Las 90–150 frases-guión constituyen, ante todo, un *banco de evaluación* (*benchmark*) de dominio clínico; por sí solas son insuficientes como único material de entrenamiento para el *fine-tuning* de NLLB. Por ello el conjunto de ajuste se amplifica con *aumento de datos* —retrotraducción (*back-translation*) y generación de variantes sintéticas (Ahmed et al., 2023; Gow-Smith & Sánchez Villegas, 2023)— y se complementa con recursos existentes para el quechua (*Huqariq*, QuBERT), reservando el *benchmark* clínico para la medición final.
Unidad muestral (registro). Cada *turno* de traducción constituye una fila del conjunto de datos, con sus campos de evaluación: dirección `quz`↔es, transcripción, traducción de referencia, WER, BLEU, chrF, MOS y latencia (véase el Anexo 1).
Tipo de muestreo. No probabilístico por conveniencia, apropiado para una lengua de bajo recurso sin corpus clínico preexistente: las frases se seleccionan por su pertinencia al dominio y por su cobertura de los escenarios de consulta, no al azar.
Participantes. Para la validación de percepción (comprensión y calidad de voz) se convoca a 10–15 voluntarios bilingües `quz`–español —estudiantes de ciencias de la salud o personal asistencial— que actúan los roles en las consultas simuladas. *No* se emplean

pacientes ni datos clínicos reales, en concordancia con los aspectos éticos del estudio.
Justificación del tamaño. El número de jueces (10–15) satisface el mínimo habitual para estimar el MOS de forma estable ($\geq$ 10 evaluadores) (International Telecommunication Union, 1996); el número de turnos (90–150) responde a la disponibilidad real de hablantes nativos de la variante de Cusco y a la naturaleza acotada del dominio. Al tratarse de una muestra pequeña, los resultados se acompañan de intervalos de confianza y del tamaño del efecto (d de Cohen), y el diseño de medidas repetidas —cada unidad como su propio control— incrementa la potencia estadística frente a un contraste entre grupos independientes.

*3.4.3 Entorno tecnológico (*setup *experimental)*

El ajuste y la evaluación se ejecutan en el entorno de la Tabla 4. El *fine-tuning* de MMS y NLLB requiere GPU; la inferencia del *pipeline* integrado se valida además en equipo de gama media, compatible con un piloto en el punto de atención.
El *fine-tuning* —fase intensiva en cómputo— se ejecuta en **GPU en la nube** (Google Colab Pro, Kaggle o créditos de nube institucional), ya que el equipo local de desarrollo (Windows 11 con WSL2, sin GPU dedicada) solo soporta con holgura la *inferencia* del *pipeline* integrado. Para acotar el costo, el ajuste emplea técnicas de bajo consumo de memoria (*LoRA*/*PEFT* (Hu et al., 2021) y precisión reducida), de modo que cada modelo se afina dentro de los límites de VRAM de una GPU de nivel medio (p. ej. T4 de 16 GB); el presupuesto de horas-GPU se detalla en el Capítulo V.

Tabla 4
Entorno de hardware y software del experimento.

Componente	**Especificación prevista**
GPU	NVIDIA con $\geq$ 12 GB VRAM (p. ej. RTX 3060/T4); créditos en la nube para fases intensivas
CPU / RAM	8 núcleos / $\geq$ 16 GB
Almacenamiento	$\geq$ 256 GB SSD
Sistema	Linux (Ubuntu 22.04) o Windows 11 con WSL2
Lenguaje	Python 3.11
Frameworks	PyTorch 2.x, Hugging Face `transformers`, `datasets`, `peft` (LoRA)
Evaluación	`jiwer` (WER), `sacrebleu` (BLEU/chrF); MOS por panel

Nota. Las herramientas corresponden a los modelos justificados en el Capítulo II (MMS, NLLB, Whisper) y a sus ecosistemas de código abierto.

3.5 Técnicas e instrumentos de recolección

- **Corpus:** Lista de vocabulario y frases de triaje/síntomas/indicaciones, construida y revisada con personal de salud (fichas de validación de contenido).

- **Registro de desempeño:** *Logs* automáticos del sistema (WER, BLEU, latencia por turno).
- **Encuesta de percepción:** Cuestionario tipo Likert (utilidad, confianza, comprensión) al personal y a los pacientes-actores.
- **Prueba de comprensión:** Tarea de recuperación de la indicación (% de aciertos) para contrastar H2 y H3.

3.6 Procedimiento metodológico

1. Construcción y validación del corpus médico Quechua–Español.
2. Ajuste (*fine-tuning*) de MMS (reconocimiento y síntesis) y, como aporte central, de NLLB para el par quechua de Cusco (`quz`)–Español.
3. Integración del *pipeline* y de la salida diferenciada por voz y texto.
4. Ejecución de consultas simuladas bajo las condiciones experimentales.
5. Registro de métricas y aplicación de instrumentos de percepción.

3.7 Protocolo de evaluación

3.7.1 Métricas de reconocimiento y traducción

La precisión del reconocimiento se mide con la **tasa de error de palabra (WER)** y la de la traducción con **BLEU** (Papineni et al., 2002) y **chrF** (Popović, 2015), adecuada para lenguas morfológicamente ricas. Sus formulaciones se definieron en el Capítulo II (ecuaciones 3, 4 y 5). Operativamente, el WER se calcula por turno sobre la transcripción del ASR y BLEU/chrF sobre la traducción del MT, en ambos sentidos `quz`↔es, comparando contra referencias validadas por hablantes nativos.

3.7.2 Métricas de calidad de voz y comprensión

La calidad de la voz sintetizada se valora con el *Mean Opinion Score* (MOS). La comprensión se mide con el porcentaje de aciertos en la recuperación de la indicación y con escalas Likert de utilidad y confianza.

3.7.3 Métricas de eficiencia

La eficiencia se cuantifica con la *latencia por turno* (tiempo entre el fin de la voz de entrada y el inicio de la voz de salida) y el consumo de recursos de cómputo.

*3.7.4 Líneas base (*baselines*) de comparación*

El desempeño del sistema ajustado se interpreta siempre contra referencias explícitas, no en abstracto. Se contrastan tres condiciones: (i) **modelos preentrenados sin ajuste** —NLLB con el quechua de Ayacucho (`quy`) y MMS base—, que fijan el punto de partida técnico; (ii) el **sistema ajustado** a la variante de Cusco (`quz`) y al dominio clínico, que es la propuesta; y (iii) la **ausencia de apoyo tecnológico**, como referencia de la comprensión médico-paciente. La mejora de (ii) sobre (i) contrasta H2 y la de (ii) sobre (iii) contrasta H3.

3.7.5 Criterios de éxito (metas cuantitativas)

El éxito del prototipo se declara verificable mediante umbrales objetivo, fijados a partir de los resultados reportados en los antecedentes (Capítulo II) y ajustados al dominio clínico y a la variante de Cusco (Tabla 5).

Tabla 5
Metas de desempeño del prototipo (criterios de éxito).

Métrica	**Componente / sentido**	**Meta objetivo**
WER	Reconocimiento (ASR), menor es mejor	≤ 25 %
BLEU	Traducción (MT), mayor es mejor	≥ 20
chrF	Traducción (MT), morfología rica	≥ 45
MOS	Calidad de voz (TTS), escala 1–5	$\geq 3{,}5$
Comprensión	% de aciertos en la indicación	≥ 80 %
Latencia	Tiempo por turno (cascada completa)	$\leq 4{,}0$ s

Nota. Elaboración propia. Umbrales de referencia para declarar viable el prototipo; se contrastan con las líneas base y pueden reajustarse tras la fase de diagnóstico. Valores anclados en los antecedentes del Capítulo II (p. ej. 26.7 BLEU en QUESPA 2025; MOS hasta 4.9 en síntesis quechua).

3.8 Métodos de análisis de datos

Estadística descriptiva para WER/BLEU/MOS/latencia y pruebas de comparación de medias/proporciones (t de Student o Wilcoxon según normalidad), con un nivel de significancia $\alpha = 0{,}05$, para contrastar las hipótesis (modelo ajustado vs. sin ajustar; texto vs. texto+voz).

La elección entre ambas pruebas se decide con un contraste previo de normalidad (Shapiro–Wilk): si los datos son normales se aplica la t de Student (paramétrica); si no, la prueba de Wilcoxon (no paramétrica, basada en rangos), adecuada para muestras pequeñas como la de este estudio.

3.9 Aspectos éticos y de gestión de datos

El estudio usa únicamente diálogos **simulados/actuados**, sin información clínica real, evitando la necesidad de aprobación de un comité de ética hospitalario para datos de pacientes. Se obtiene consentimiento informado de los participantes voluntarios y se anonimizan las grabaciones, en cumplimiento de los principios éticos de la investigación. Los datos se almacenan de forma segura y se usan solo con fines de investigación.
Aunque no se manejan datos de pacientes, el proyecto se acoge a la categoría de **riesgo mínimo** y tramita la conformidad de la instancia correspondiente de la UNSAAC —la Escuela Profesional de Ingeniería Informática y de Sistemas y, de requerirse, el comité institucional de ética de la investigación— conforme al reglamento de grados y títulos vigente. El consentimiento informado (Anexo 4), la participación voluntaria con derecho de retiro sin perjuicio y la anonimización de las grabaciones constituyen las garantías éticas del estudio.

3.10 Matriz de consistencia

Cada fila articula, en horizontal, problema, objetivo, hipótesis, variables, indicadores y método de análisis (Tabla 6).

Tabla 6

Matriz de consistencia del proyecto.

Tema: Desarrollo de un sistema bidireccional de traducción de voz Quechua–Español mediante arquitecturas de transformadores multimodales para consultas médicas en Cusco

Nivel	Problema	Objetivo	Hipótesis	Variables	Dimensiones / indicadores	Metodología
General	¿Cómo desarrollar el sistema bidireccional de traducción de voz QU–ES para la comunicación médico-paciente, mediante arquitecturas de transformadores multimodales, en Cusco?	Desarrollar el sistema mediante el ajuste de modelos preentrenados (MMS, NLLB) para la comunicación médico-paciente en Cusco.	Mejora significativamente la comunicación médico-paciente frente a la ausencia de apoyo.	**VI:** Uso y modalidad (texto / texto+voz). **VD:** Precisión, voz, comprensión.	WER, BLEU, chrF, MOS; % comprensión; latencia (s).	Aplicada; cuantitativo; cuasi-exp. (medidas repetidas); t / Wilcoxon ($\alpha = 0{,}05$).
Específico 1 (Diagnóstico)	¿Cuáles son las barreras de comunicación y los requisitos del corpus clínico QU–ES?	Caracterizar las barreras y los requerimientos del corpus clínico QU–ES.	(Descriptiva) Las barreras definen los requisitos del corpus clínico para el ajuste.	Barreras; corpus (calidad y cobertura).	Cobertura léxica; % de concordancia.	Nivel descriptivo; juicio de expertos; fichas de validación.
Específico 2 (Construcción)	¿Cómo desarrollar el sistema (corpus + *fine-tuning* de MMS y NLLB `quy`→`quz` + *pipeline*)?	Desarrollar el sistema: corpus + *fine-tuning* de MMS y NLLB (`quy`→`quz`), integrados en el *pipeline*.	El *fine-tuning* reduce el WER y mejora el BLEU/chrF frente a los modelos sin ajustar.	Modelo (base vs. ajustado); *pipeline*.	WER; BLEU; chrF; latencia (s).	Nivel aplicativo; *logs* automáticos; t / Wilcoxon (ajustado vs. base).
Específico 3 (Validación)	¿En qué medida el sistema mejora la precisión, la voz y la comprensión frente a la ausencia de apoyo?	Evaluar la mejora en precisión, voz y comprensión en consultas simuladas.	Mejora significativamente la precisión, la voz y la comprensión mutua.	Precisión; voz; comprensión; percepción.	WER/BLEU/chrF; MOS; % de aciertos; Likert.	Nivel explicativo; experimental; estadística inferencial.

Nota. Elaboración propia. Las tres filas específicas siguen el modelo de ingeniería de tres fases (diagnóstico, construcción y validación), en correspondencia 1 a 1 con los objetivos. VI/VD: variable independiente/dependiente. Las fórmulas de WER, BLEU, chrF y MOS se definen en el Capítulo II.

Capítulo IV

Estudio de factibilidad

4.1 Enfoque adoptado

El proyecto es viable porque reutiliza modelos preentrenados de código abierto (MMS, NLLB, Whisper) mediante ajuste fino, lo que reduce drásticamente los requisitos de datos y cómputo frente a entrenar desde cero. La factibilidad se analiza en sus dimensiones técnica, económica y operativa.

4.2 Factibilidad técnica

4.2.1 Hardware, cómputo e inferencia

El ajuste de modelos preentrenados puede realizarse en una estación con GPU y complementarse con créditos de GPU en la nube para las fases intensivas. La inferencia del *pipeline* integrado es ejecutable en equipo de gama media, compatible con un piloto en el punto de atención. En concreto, el *fine-tuning* se realiza en **GPU en la nube** (Colab Pro, Kaggle o nube institucional) con técnicas de bajo consumo de memoria (*LoRA*/*PEFT*), dado que el equipo local (WSL2 sin GPU dedicada) se reserva para la inferencia; el presupuesto de horas-GPU se refleja en la factibilidad económica.

4.2.2 Estrategia de datos

El cuello de botella es el corpus clínico Quechua–Español, que se construirá de forma acotada (vocabulario y frases de triaje, síntomas e indicaciones) y se complementará con recursos existentes (*Huqariq*, QuBERT) y datos sintéticos cuando sea pertinente.

4.2.3 Herramientas y software

Se emplearán bibliotecas de código abierto para habla y traducción (modelos MMS, NLLB y Whisper de Meta/OpenAI y sus ecosistemas), herramientas de evaluación (cálculo de WER, BLEU y chrF) y entornos reproducibles de *fine-tuning*.

4.3 Factibilidad económica

El presupuesto estimado (Tabla 9) asciende a **S/ 7 350.00**, dominado por hardware con GPU y créditos de cómputo; es asumible en el marco de un trabajo de tesis y puede financiarse con recursos propios y/o apoyo institucional.

4.4 Factibilidad operativa

La validación con consultas simuladas y participantes voluntarios evita la dependencia de aprobaciones clínicas complejas y permite ejecutar los experimentos dentro del cronograma anual (12 meses), en un centro de salud de referencia en Cusco.

4.5 Análisis de riesgos y mitigación

Los principales riesgos del proyecto y sus medidas de mitigación se resumen en la Tabla 7; se priorizan por su impacto sobre los objetivos específicos.

Tabla 7
Matriz de riesgos y mitigación.

Riesgo	**Prob./Imp.**	**Mitigación**
Corpus clínico insuficiente para el ajuste	Alta / Alto	Aumento de datos (retrotraducción, sintéticos) y reuso de *Huqariq*/QuBERT; el corpus se usa sobre todo como *benchmark*.
Escasa disponibilidad de hablantes nativos `quz`	Media / Alto	Convocatoria temprana de voluntarios bilingües; validación por paneles reducidos (≥ 3 revisores).
Latencia del *pipeline* superior a la meta	Media / Medio	Modelos ligeros, cuantización y evaluación por etapas (presupuesto de la Tabla 2).
Costo/acceso a GPU en la nube	Media / Medio	*LoRA*/*PEFT* y precisión reducida; créditos gratuitos (Colab/Kaggle) y nube institucional.
Baja ganancia dialectal `quy`→`quz`	Media / Alto	Segmentación morfológica, validación con nativos y líneas base de comparación.

Nota. Elaboración propia. Prob./Imp.: probabilidad e impacto estimados.

4.6 Viabilidad y sostenibilidad

El proceso (corpus + ajuste + evaluación) es replicable en otras variantes del quechua o en otros dominios, y el uso de modelos de código abierto favorece la continuidad y la apropiación local de la tecnología.

Capítulo V

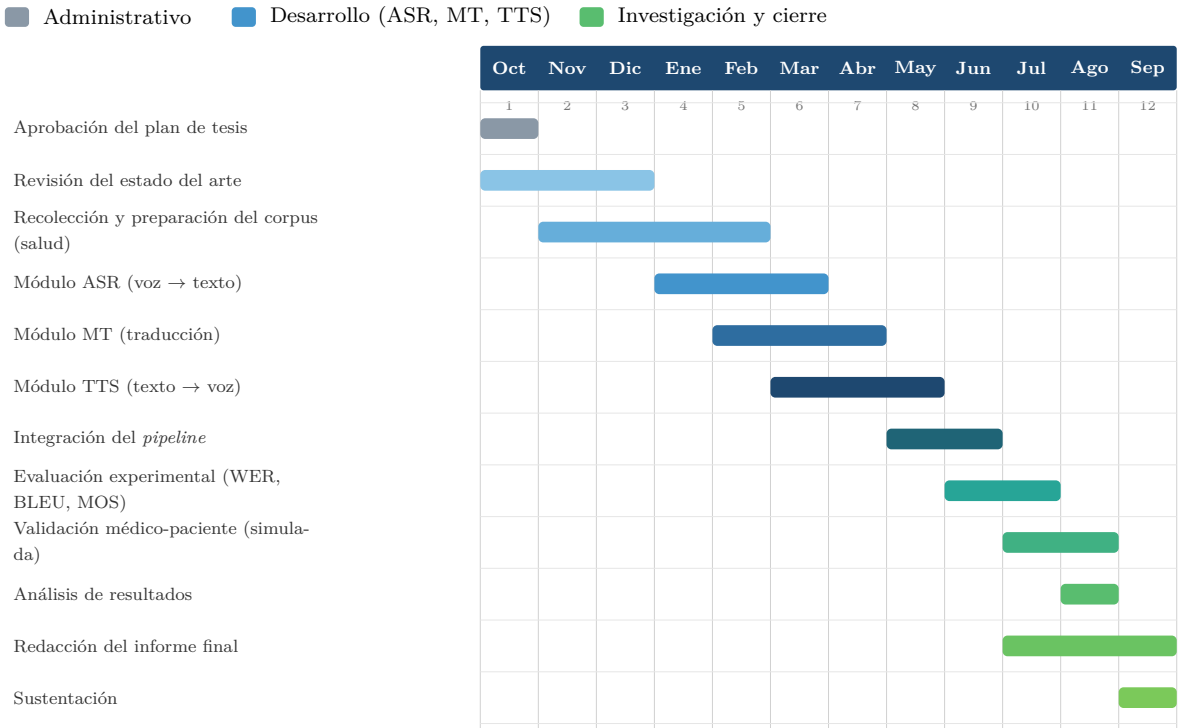
Aspectos administrativos

5.1 Cronograma de actividades

El proyecto se ejecuta en **12 meses (octubre 2026 – septiembre 2027)**, organizado por meses. La Tabla 8 presenta el diagrama de Gantt, con las actividades agrupadas en tres fases —*administrativa*, de *desarrollo* (ASR, MT y TTS) e *investigación y cierre*—; los módulos ASR, MT y TTS se ejecutan de forma parcialmente paralela mediante el ajuste de modelos preentrenados.

Tabla 8

Cronograma de actividades (octubre 2026 – septiembre 2027), por meses.



Nota. Elaboración propia. Cada columna representa un mes (octubre 2026 – septiembre 2027); el color identifica la fase y el solapamiento de las barras refleja el desarrollo parcialmente paralelo de los módulos ASR, MT y TTS.

5.2 Presupuesto y financiamiento

La Tabla 9 resume los recursos estimados para el desarrollo del proyecto.

Tabla 9
Recursos para el desarrollo del proyecto de tesis (soles).

Tipo	**Descripción**	**Costo (S/)**
Hardware	Laptop/PC con GPU (entrenamiento y *fine-tuning*)	4 500.00
Cómputo	Créditos de GPU en la nube (horas de ajuste)	900.00
Datos	Grabación y validación del corpus clínico (incentivos a hablantes)	800.00
Administrativos	Impresiones, inscripción y trámites de tesis	600.00
Movilidad	Traslados al centro de salud y a comunidades	300.00
Otros	Gastos no previstos	250.00
Total		**7 350.00**

Nota. Montos estimados en soles (S/). Elaboración propia.

5.3 Equipo de investigación

La Tabla 10 detalla el equipo responsable del proyecto.

Tabla 10
Equipo de investigación.

Rol	**Responsable / función**
Tesista	Alain Armando Condori Contreras —diseño, desarrollo y evaluación del sistema—.
Asesor	Mtro. Ing. Raúl Huillca Huallparimachi —orientación metodológica y técnica—.
Colaboradores	Personal de salud bilingüe (validación del corpus) y participantes voluntarios (consultas simuladas).

Nota. Elaboración propia. Los colaboradores intervienen en la validación del corpus y en la actuación de las consultas simuladas.

Referencias

Nota sobre la vigencia de las fuentes. Se priorizaron publicaciones de los últimos cinco años (2021–2026). Las referencias anteriores se conservan por ser (a) obras *seminales* que definen los métodos empleados —el *Transformer* (Vaswani et al., 2017), BLEU (Papineni et al., 2002) y chrF (Popović, 2015)—; (b) *libros* de metodología en su edición vigente (Hernández-Sampieri & Mendoza Torres, 2018); y (c) *fuentes primarias oficiales* o trabajos fundacionales del PLN para el quechua —los Censos Nacionales (Instituto Nacional de Estadística e Informática, 2017) y los primeros sistemas de traducción (Ortega et al., 2020) y reconocimiento de voz (Zevallos et al., 2020) para esta lengua—.

Ahmed, N., Flechas Manrique, N., & Petrović, A. (2023). Enhancing Spanish-Quechua Machine Translation with Pre-Trained Models and Diverse Data Sources: LCT-EHU at AmericasNLP Shared Task. *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 156-162. https://doi.org/10.18653/v1/2023.americasnlp-1.16

Al Shamsi, H., Almutairi, A. G., Al Mashrafi, S., & Al Kalbani, T. (2020). Implications of language barriers for healthcare: A systematic review. *Oman Medical Journal*, *35*(2), e122. https://doi.org/10.5001/omj.2020.40

Alvarez-Crespo, A., Miranda-Salazar, D., & Ugarte, W. (2023). Model for Real-Time Subtitling from Spanish to Quechua Based on Cascade Speech Translation. *Proceedings of the International Conference on Agents and Artificial Intelligence (ICAART)*, *3*, 837-844. https://doi.org/10.5220/0011783300003393

Begazo Solís, C. L. (2026). *Barreras lingüísticas y culturales en la atención hospitalaria: la experiencia de pacientes quechua-hablantes* [Proyecto de investigación]. Universidad Peruana Cayetano Heredia [Repositorio institucional UPCH].

Chen, C.-C., Chen, W., Zevallos, R., & Ortega, J. E. (2024). Evaluating Self-Supervised Speech Representations for Indigenous American Languages. *Proceedings of LREC-COLING 2024*, 6444-6450.

Chen, W., & Fazio, B. (2021). Morphologically-Guided Segmentation for Translation of Agglutinative Low-Resource Languages. *Proceedings of the 4th Workshop on Technologies for Machine Translation of Low-Resource Languages (LoResMT)*, 20-31.

Cuaila, R. G. M. (2022). *Nivel de conocimiento del quechua y su relación con la calidad de atención del personal asistencial en servicios de salud de Huaylas, Áncash, 2022* [Tesis de licenciatura]. Universidad César Vallejo [Repositorio institucional UCV].

Cueva Medina, B., Tuco Casquino, G. F., & Sulla-Torres, J. (2024). Development of a Neural Machine Translation Model Optimized with BERT for Translation from Quechua to Spanish. *Proceedings of the LACCEI International Multi-*

conference for Engineering, Education and Technology. https://doi.org/10.18687/LACCEI2024.1.1.1636

Dhawan, A., Driggers-Ellis, C., Grant, C., & Wang, D. (2026). Improving Indigenous Language Machine Translation with Synthetic Data and Language-specific Preprocessing. *Proceedings of the 9th Workshop on Technologies for Machine Translation of Low Resource Languages (LoResMT)*, 119-126. https://doi.org/10.18653/v1/2026.loresmt-1.10

Ebrahimi, A., de Gibert, O., Vázquez, R., Coto-Solano, R., et al. (2024). Findings of the AmericasNLP 2024 Shared Task on Machine Translation into Indigenous Languages. *Proceedings of the 4th Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 236-246. https://doi.org/10.18653/v1/2024.americasnlp-1.28

EsSalud. (2023, noviembre). *Presidenta de EsSalud reactiva central telefónica en quechua, en beneficio de 70 mil asegurados quechuahablantes del Cusco* [Nota de prensa]. Gob.pe. https://www.gob.pe/essalud

Fundación Dispurse. (2023). *Programas de alfabetización en Apurímac, Cajamarca y Cusco* [Nota de prensa]. Caretas.

Gow-Smith, E., & Sánchez Villegas, D. (2023). Sheffield's Submission to the AmericasNLP Shared Task on Machine Translation into Indigenous Languages. *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 192-199.

Guzman, Y., Tavara, A., Zevallos, R., & Vega, H. (2021). Implementation of a Bilingual Participative Argumentation Web Platform for Collection of Spanish Text and Quechua Speech. *2021 International Conference on Electrical, Communication, and Computer Engineering (ICECCE)*, 1-6. https://doi.org/10.1109/ICECCE52056.2021.9514251

Hernández-Sampieri, R., & Mendoza Torres, C. P. (2018). *Metodología de la investigación: las rutas cuantitativa, cualitativa y mixta*. McGraw-Hill Interamericana.

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). LoRA: Low-rank adaptation of large language models. https://arxiv.org/abs/2106.09685

Huamán Curo, E., & Pineda Ancco, F. (2026). Quechua Speech Synthesizers. *Communications in Computer and Information Science, 2895*, 167-183. https://doi.org/10.1007/978-3-032-20322-9_12

Instituto Nacional de Estadística e Informática. (2017). *Censos Nacionales 2017: XII de Población, VII de Vivienda, III de Comunidades Indígenas*. INEI. Lima, Perú.

Instituto Nacional de Estadística e Informática. (2023, enero). *Día Internacional de la Educación: en Perú el 22.8 % de mujeres rurales no sabe leer ni escribir* [Nota de prensa]. INEI.

International Telecommunication Union. (1996). *Methods for subjective determination of transmission quality* (Recommendation ITU-T P.800). ITU-T. Ginebra, Suiza.

Joshi, P., Santy, S., Budhiraja, A., Bali, K., & Choudhury, M. (2020). The State and Fate of Linguistic Diversity and Inclusion in the NLP World. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*, 6282-6293. https://doi.org/10.18653/v1/2020.acl-main.560

Mager, M., Oncevay, A., Ebrahimi, A., Ortega, J., Rios, A., Fan, A., Gutierrez-Vasques, X., Chiruzzo, L., Giménez-Lugo, G., Ramón, R., et al. (2021). Findings of the AmericasNLP 2021 shared task on open machine translation for Indigenous languages of the Americas. *Proceedings of the First Workshop on Natural Language Processing for Indigenous Languages of the Americas*, 202-217.

Decreto Supremo N.º 016-2016-SA: Aprueban la Política Sectorial de Salud Intercultural, Lima, Perú (2016, abril).

Moreno Véliz, O. (2021). The REPUcs' Spanish–Quechua Submission to the AmericasNLP 2021 Shared Task on Open Machine Translation. *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 241-247.

NLLB Team. (2022). *No language left behind: Scaling human-centered machine translation* [Incluye el quechua de Ayacucho (quy); no la variante de Cusco (quz)]. arXiv: 2207.04672. https://arxiv.org/abs/2207.04672

Oncevay, A. (2021). Peru is Multilingual, Its Machine Translation Should Be Too? *Proceedings of the Workshop on NLP for Indigenous Languages of the Americas (AmericasNLP)*, 194-201. https://doi.org/10.18653/v1/2021.americasnlp-1.22

Ortega, J. E., Castro Mamani, R., & Cho, K. (2020). Neural machine translation with a polysynthetic low resource language. *Machine Translation*, *34*(4), 325-346.

Ortega, J. E., Zevallos, R., & Chen, W. (2023). QUESPA Submission for the IWSLT 2023 Dialect and Low-resource Speech Translation Tasks. *Proceedings of the 20th International Conference on Spoken Language Translation (IWSLT)*, 261-268.

Ortega, J. E., Zevallos, R., Chen, W., & Abdulmumin, I. (2025). QUESPA Submission for the IWSLT 2025 Dialectal and Low-resource Speech Translation Task. *Proceedings of the 22nd International Conference on Spoken Language Translation (IWSLT)*, 260-268. https://doi.org/10.18653/v1/2025.iwslt-1.25

Papineni, K., Roukos, S., Ward, T., & Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, 311-318.

Popović, M. (2015). chrF: Character n-gram F-score for automatic MT evaluation. *Proceedings of the Tenth Workshop on Statistical Machine Translation (WMT)*, 392-395.

Pratap, V., Tjandra, A., Shi, B., Tomasello, P., Babu, A., Kundu, S., Elkahky, A., Ni, Z., Vyas, A., Fazel-Zarandi, M., Baevski, A., Adi, Y., Zhang, X., Hsu, W.-N., Conneau, A., & Auli, M. (2024). Scaling speech technology to 1,000+ languages. *Journal of Machine Learning Research*, *25*(97), 1-52.

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. *Proceedings of Machine Learning Research*, *202*, 28492-28518.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*, *30*, 5998-6008.

Zevallos, R., Bel, N., Cámbara, G., Farrús, M., & Luque, J. (2022). Data Augmentation for Low-Resource Quechua ASR Improvement. *Proc. Interspeech 2022*, 3518-3522. https://doi.org/10.21437/Interspeech.2022-770

Zevallos, R., Camacho, L., & Melgarejo, N. (2022). Huqariq: A multilingual speech corpus of native languages of Peru for speech recognition. *Proceedings of the 13th Language Resources and Evaluation Conference (LREC)*, 5029-5034.

Zevallos, R., Cordova, J., & Camacho, L. (2020). Automatic Speech Recognition of Quechua Language Using HMM Toolkit. *Communications in Computer and Information Science*, *1070*, 61-68. https://doi.org/10.1007/978-3-030-46140-9_6

Zevallos, R., Ortega, J. E., Chen, W., Castro, R., Bel, N., Yoshikawa, C., Ventura, R., Aradiel, H., & Melgarejo, N. (2022). Introducing QuBERT: A Large Monolingual Corpus and BERT Model for Southern Quechua. *Proceedings of the Third Workshop on Deep Learning for Low-Resource NLP (DeepLo)*, 1-13.

Anexos

Anexo 1: Ficha técnica de registro experimental

Plantilla para registrar cada *turno de traducción* durante las consultas simuladas.

Tabla 11
Ficha técnica de registro por turno (plantilla).

Campo	**Valor registrado**
ID de turno / sesión	_____
Escenario (triaje/síntomas/indicaciones)	_____
Dirección (`quz`→es / es→`quz`)	_____
Transcripción ASR / WER	_____
Traducción MT / BLEU / chrF	_____
Calidad de voz (MOS)	_____
Latencia por turno (s)	_____
Observaciones	_____

Nota. Elaboración propia. Se completa una ficha por cada turno de traducción registrado.

Anexo 2: Plantilla del banco de frases de consulta (evaluación)

Guión base de frases por escenario; el equivalente en quechua de Cusco se valida con hablantes nativos antes de su uso.

Tabla 12
Banco de frases de consulta simulada (ejemplos; `quz` por validar).

Categoría	**Enunciado (español)**	**Equivalente (`quz`)**
Triaje	¿Qué lo trae a la consulta?	[por validar]
Triaje	¿Hace cuánto tiempo se siente mal?	[por validar]
Síntomas	¿Dónde le duele?	[por validar]
Síntomas	¿Tiene fiebre o escalofríos?	[por validar]
Indicaciones	Tome esta pastilla cada 8 horas.	[por validar]
Indicaciones	Regrese en 3 días si no mejora.	[por validar]

Nota. Elaboración propia. El equivalente en quechua de Cusco (`quz`) se valida con hablantes nativos antes de su uso.

Anexo 3: Cuestionario de percepción (escala Likert)

Escala de 1 (*totalmente en desacuerdo*) a 5 (*totalmente de acuerdo*); se aplica al personal y a los pacientes-actores.

Tabla 13
Ítems del cuestionario de percepción.

N.º	Ítem	1–5
1	El sistema facilitó la comunicación durante la consulta.	_____
2	Confío en la traducción que entregó el sistema.	_____
3	Comprendí con claridad las indicaciones médicas.	_____
4	La voz sintetizada fue clara y natural.	_____
5	El tiempo de respuesta del sistema fue adecuado.	_____
6	Usaría el sistema en una consulta real.	_____

Nota. Elaboración propia. Escala Likert de 1 (totalmente en desacuerdo) a 5 (totalmente de acuerdo).

Anexo 4: Modelo de consentimiento informado

Yo, _____, declaro haber sido informado(a) sobre los objetivos del estudio "Desarrollo de un sistema bidireccional de traducción de voz Quechua–Español mediante arquitecturas de transformadores multimodales para consultas médicas en Cusco". Entiendo que participaré de forma voluntaria en consultas ***simuladas*** *—sin datos clínicos reales—, que las grabaciones serán anonimizadas y usadas solo con fines de investigación, y que puedo retirarme en cualquier momento sin perjuicio.*

_____ _____

Firma del participante Fecha